

Session7/8

베이지안 네트워크

Causal Bayesian Network

용어 정의

1. Probability

- $P(A)$: marginal Prob
- $P(A|B)$: Conditional Prob
- $P(A \cap B) = P(A, B) = P(A)P(B|A) = P(B)P(A|B)$
- Bayes's Th : $P(B|A) = \frac{P(B)P(A|B)}{P(A)}$

2. Marginalize

- $P(A) = \sum_B P(B)P(A|B) = \int_B P(B)P(A|B)$

3. Independent

- $A \perp\!\!\!\perp B \Leftrightarrow P(A) = P(A|B)$
- $P(A, B) = P(A)P(B)$
- conditional independent : $P(A, B|C) = P(A|C)P(B|C)$

가정

1. Causal Markov Assumption(under DAG)

- 그래프가 주어졌을때 joint prob을 계산할 때 본인에게 화살표를 주는 변수에만 condition하다.
- $X \rightarrow Y \rightarrow Z : P(X, Y, Z) = P(X)P(Y|X)P(Z|Y)$
- 위 과정을 Bayesian Network Factorization라고 한다.
- Bayesian Network Factorization이 Causal Bayesian Network을 이해하는 첫걸음.

Mediator

$$X \rightarrow M \rightarrow Y$$

- $P(X, Y, M) = P(X)P(M|X)P(Y|M)$
- 목표 : $P(X, Y) = P(X)P(Y)$?
- $P(X, Y) = \sum_M P(X, Y, M) = P(X) \sum_M P(M|X)P(Y|M)$
- $\sum_M P(Y)P(Y|M) = P(Y)$
- 즉, $P(M|X) = P(M)$ 인지 확인하면 된다.
 - 위 식이 성립하다는 것은 M과 X는 독립이라는 것이지만, M은 X의 영향을 받기 때문에 독립일 수 없다.
- 따라서, X와 Y는 association이 생긴다.

$$X \rightarrow \textcircled{M} \rightarrow Y$$

목표 : $P(X, Y|M) = P(X|M)P(Y|M)$?

$$P(X, Y, M) = P(X)P(M|X)P(Y|M)$$


$$\Rightarrow P(X, Y|M) = \frac{P(X)P(M|X)P(Y|M)}{P(M)}$$

$$= \frac{P(M)P(X|M)P(Y|M)}{P(M)}$$

$$= P(X|M)P(Y|M)$$

M을 conditioning하면 X와 Y는 독립임을 증명.

Confounder



목표: $P(X, Y) = P(X)P(Y)$?


$$P(X, Y, C) = P(X|C) P(Y|C) P(C)$$

$$\begin{aligned} P(X, Y) &= \sum_c P(X, Y, c) = \sum_c P(X|c) \underline{P(Y|c)P(c)} \\ &= P(X, c) = P(Y)P(C|Y) \\ &= P(Y) \sum_c P(X|c) \underline{P(c|Y)}, \quad P(X) = \sum_c \underline{P(c)} P(X|c) \end{aligned}$$

$\Rightarrow P(c) = P(c|Y)$?

$\therefore X \not\perp Y$.

confounder가 있을 때 X와 Y는 association이 있다.



목표: $P(X, Y|C) = P(X|C)P(Y|C)$


$$P(X, Y, C) = P(X|C) P(Y|C) P(C)$$

$$\Rightarrow P(C)P(X, Y|C) = P(X|C)P(Y|C)P(C).$$

$$\therefore P(X, Y|C) = P(X|C)P(Y|C)$$

confounder를 condition했을 때 X와 Y는 조건부 독립이다.

Collider



목표: $P(X, Y) = P(X)P(Y)$?

$$P(X, Y, C) = P(X)P(Y)P(C|X, Y)$$

$$P(X, Y) = \sum_C P(X, Y, C) = P(X)P(Y) \underbrace{\sum_C P(C|X, Y)}_{=1}$$

$$\therefore X \perp\!\!\!\perp Y$$

Collider가 있을 때 X와 Y는 독립



목표: $P(X, Y | C) = P(X | C)P(Y | C)$. 를 다른 시각으로 보면,

$P(X | C) = P(X | C, Y)$. 즉, C라는 조건이 있을 때 Y를 추가하더라도 확률이 같다면 C라는 조건 하에서 X, Y는 독립.

$$\Rightarrow P(X | C) = \frac{P(X)P(C | X)}{P(C)}, \quad P(X | C, Y) = \frac{P(X | Y)P(C | Y, X)}{P(C | Y)}.$$

\Rightarrow X, Y는 조건이 없으면 독립, $P(X) = P(X | Y)$.

$$\frac{P(C | X)}{P(C)} \neq \frac{P(C | Y, X)}{P(C | Y)}$$


$\therefore \frac{P(C | X)}{P(C)}$: X를 conditioning 하지 않았을 때 대비해서 conditioning 했을 때의 C의 확률의 ratio \Rightarrow Effect of X on C.

$\frac{P(C | Y, X)}{P(C | Y)}$: Effect of X on C after controlling for Y.

\Rightarrow regression 관찰 : 통제변수를 추가했을 때 메인변수의 계수는 변한다.
즉, X가 C에 미치는 효과라 Y를 control 했을 때 X가 C에 미치는 효과는 같아진다.

Collider를 통제했을 때 X와 Y는 독립이 아니다.

Correlation과 Causation이 다른 이유




$$P(X, Y, C) = P(X|C)P(Y|X, C)P(C)$$

$$\Rightarrow P(X)P(Y, C|X) = P(X|C)P(Y|X, C)P(C).$$

$$P(Y, C|X) = \frac{\overbrace{P(X|C)P(C)}^{= P(X)P(C|X)} P(Y|X, C)}{P(X)}$$

$$= P(C|X)P(Y|X, C)$$

$$P(Y|X) = \sum_c P(Y, C|X) = \boxed{\sum_c P(C|X)P(Y|X, C)}$$



$$\text{causal effect} = P(Y|do(X))$$

$$P(do(X), Y, C) = P(do(X))P(Y|do(X), C)P(C).$$

$$P(Y, C|do(X)) = P(Y|do(X), C)P(C)$$

$$P(Y|do(X)) = \sum_c P(Y, C|do(X))$$

$$= \boxed{\sum_c P(Y|do(X), C)P(C)}$$

$$\Rightarrow P(C|X) = P(C) ?$$

X와 C는 독립일 수 있기 때문에 같지 않다.

∴ Correlation \neq causation.